

ПРАВИТЕЛЬСТВО РОССИЙСКОЙ ФЕДЕРАЦИИ
ФГАОУ ВО НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»

Факультет компьютерных наук

Образовательная программа «Прикладная математика и информатика»

Отчет об исследовательском проекте на тему:

**Влияние типа данных на оптимизацию в физически информированных
нейронных сетях**

Выполнил:

студент группы БПМИ243

Тиханов Леонид Александрович

Принял руководитель проекта:

Блуменау Марк Ильич

Преподаватель

Департамент больших данных и
информационного поиска

Москва 2026

Содержание

Аннотация	4
1 Введение	5
2 Обзор литературы	5
2.1 Physics-Informed Neural Networks	5
2.2 Failure modes при обучении PINN	7
2.3 Сэмплирование точек и распространение ошибки	7
2.4 Оптимизация и ландшафт функции потерь	7
2.5 Низкая точность в классическом deep learning	8
2.6 Смешанная точность в scientific machine learning	9
2.7 FP64 как возможное объяснение failure modes	9
3 Постановка задачи	10
3.1 Общая схема PINN	10
3.2 Функция потерь	11
3.3 Рассматриваемые PDE	11
3.4 Сравнимые типы данных	12
3.5 Метрики качества	12
4 Реализация экспериментов	13
4.1 Архитектура нейронной сети	13
4.2 Автоматическое дифференцирование и вычисление невязок	13
4.3 Оптимизация: Adam + L-BFGS	15
5 Результаты экспериментов	16
5.1 Heat1D	17
5.2 Helmholtz1D	17
5.3 Convection1D	20
5.4 Burgers1D: смешанный пример	21
6 Обсуждение результатов	22
7 Заключение	23

Список литературы	25
Приложение	27
Пробные запуски FP16	27

Аннотация

Работа посвящена исследованию влияния численной точности на обучение физически информированных нейронных сетей. PINN - это нейронные сети, используемые для решения дифференциальных уравнений. В большом количестве работ описаны проблемы с их обучением, так называемые failure modes. Вопрос работы состоит в том, как переход от FP32 к FP64 влияет на оптимизацию PINN.

Эксперименты на классических дифференциальных уравнениях показали, что для задач со сложным ландшафтом потерь переход к формату FP64 позволяет преодолеть оптимизационные барьеры. Но в случае простых задач или наоборот сложных нелинейных систем повышение разрядности не является универсальным решением

1 Введение

В этой работе PINN используются как модель для сравнения численной точности при обучении. Основная цель - проверить, как одинаковая архитектура ведёт себя при вычислениях в FP32 и FP64.

На практике зачастую во время обучения PINN возникают нестабильности. Возможна ситуация, когда функция потерь принимает достаточно небольшие значения, а реальная ошибка относительно точного решения остается существенной. В литературе это принято называть *failure modes*.

В рамках этой проблемы особого внимания требует численная точность вычислений. Как правило, в глубинном обучении используется FP32 или более низкие форматы для ускорения обучения. При этом ошибки округления могут влиять не только на финальный результат, но и на процесс сходимости.

Целью работы является исследование влияния FP32 и FP64 на качество и устойчивость обучения физически информированных нейронных сетей.

2 Обзор литературы

2.1 Physics-Informed Neural Networks

Физически информированные нейронные сети появились как способ объединить нейросетевую аппроксимацию и информацию о физической модели задачи. Базовая идея подхода была сформулирована в работе Raissi, Perdikaris и Karniadakis [1]. В отличие от обычного обучения по данным, PINN использует не только значения функции в известных точках, но и дифференциальное уравнение, которому должно удовлетворять искомое решение.

В прямой задаче требуется найти функцию $u(x, t)$, удовлетворяющую некоторому дифференциальному уравнению

$$\mathcal{N}[u](x, t) = 0$$

где $\mathcal{N}$ - дифференциальный оператор. В PINN решение заменяется ней-

росетевой аппроксимацией $u_\theta(x, t)$. После этого производные, входящие в уравнение, вычисляются с помощью автоматического дифференцирования. Таким образом модель одновременно приближает решение на известных данных и пытается удовлетворять свойствам точного решения, описанным с помощью уравнения.

Как правило функция потерь PINN выглядит как

$$\mathcal{L} = \mathcal{L}_{data} + \lambda_f \mathcal{L}_f + \lambda_{bc} \mathcal{L}_{bc} + \lambda_{ic} \mathcal{L}_{ic}.$$

$\mathcal{L}_{data}$ отвечает за ошибку на известных наблюдениях, $\mathcal{L}_f$ — за невязку дифференциального уравнения во внутренних точках области, $\mathcal{L}_{bc}$ и $\mathcal{L}_{ic}$ задают выполнение граничных и начальных условий. Если данных мало, физическая часть loss позволяет всё равно ограничить множество возможных решений и использовать известную структуру задачи.

В работе [1] выделяют две постановки задачи: прямая и обратная. В случае прямой задачи известны параметры уравнения и необходимо искать решение. В обратной задаче параметры уравнения не известны и необходимо восстанавливать их по наблюдениям. В данной работе рассматривается прямая задача.

Так же в PINN различают непрерывные и дискретные по времени подходы [1]. В непрерывном варианте сеть аппроксимирует решение на всей области, а производные по времени и пространству считаются напрямую через автоматическое дифференцирование. В дискретном варианте используются временные методы, например схемы Рунге–Кутты, связывающие значения решения на соседних временных слоях. В данной работе используется непрерывная постановка.

Главное преимущество PINN состоит в том, что мы используем известную нам информацию о физической модели в виде уравнения. Это делает метод привлекательным для задач научного машинного обучения, где известна модель процесса, но получение большого количества точных данных может быть дорогим или невозможным.

2.2 Failure modes при обучении PINN

Несмотря на простую идею, PINN часто оказываются сложными в оптимизации. На практике возможна ситуация, когда значение функции потерь становится малым, но реальная ошибка относительно точного решения остаётся большой. Такие ситуации принято называть *failure modes*.

Одна из ключевых работ по этой теме - *Characterizing possible failure modes in physics-informed neural networks* [2]. В ней авторы показывают, что *failure modes* могут возникать не из-за недостаточной выразительности сети, а из-за сложности оптимизации. Авторы связывают это с ландшафтом функции потерь и показывают, что разные варианты обучения могут существенно менять результат.

2.3 Сэмплирование точек и распространение ошибки

Альтернативным подходом к решению проблемы *failure modes* является адаптивное сэмплирование. В классическом варианте эти точки выбираются случайно по всей области. Но в какой-то момент может образоваться ситуация, что модель лучше выучила какие-то определенные области (скорее всего более простые) и хуже другие.

Например, в стратегии R3 Sampling [3] набор коллокационных точек динамически обновляется: алгоритм сохраняет точки с высокой невязкой и удаляет те, где сеть уже хорошо аппроксимировала решение. Успешность таких методов на классических бенчмарках доказывает, что стагнация оптимизатора может быть вызвана не только вычислительной точностью, но и неравномерным распределением градиентов по пространственной области.

2.4 Оптимизация и ландшафт функции потерь

Проблемы PINN также активно рассматриваются с точки зрения ландшафта функции потерь и выбора оптимизатора. В работе *Challenges*

in Training PINNs: A Loss Landscape Perspective авторы связывают трудности обучения с плохой обусловленностью loss и показывают, что стандартные методы оптимизации могут быть недостаточными [4].

Как правило при обучении PINN сначала используют Adam для получения хорошего начального приближения, а затем спомощью L-BFGS уточняют решение. В работе [4] подчёркивается, что Adam и L-BFGS по отдельности могут работать хуже, чем их последовательное применение. При этом даже связка Adam+L-BFGS не всегда полностью решает проблему плохой обусловленности. Авторы предлагают более сложный метод NysNewton-CG, который использует приближение второго порядка и может давать улучшение на ряде задач.

Данные статьи объясняют то, почему в экспериментах разумнее использовать Adam+L-BFGS вместе а не по отдельности. Следовательно, для корректного сравнения типов данных необходимо фиксировать архитектуру и метод оптимизации

2.5 Низкая точность в классическом deep learning

В классическом глубинном обучении существует тренд на то, что развитие вычислений связано со снижением размерности данных. Стандартным форматом данных можно считать FP32, но часто для ускорения обучения и уменьшения расхода памяти применяются более компактные форматы. Это объясняется тем, что многие нейросетевые модели при использовании специальных методов стабилизации обучения устойчивы к небольшим ошибкам округления.

Одна из ранних работ в этом направлении - Deep Learning with Limited Numerical Precision [5]. В ней показывается, что при использовании стохастического округления обучение нейросетей возможно даже при заметно ограниченной численной точности. Такой подход позволяет уменьшить вычислительные затраты по сравнению с FP32 и при этом сохранить приемлемое качество в ряде задач.

Стоит упомянуть так же и квантование нейронных сетей. Обзор A Survey of Quantization Methods for Efficient Neural Network Inference

систематизирует методы перевода весов и активаций из высокоточных форматов в более компактные представления [6]. Главная цель таких методов - ускорить инференс и уменьшить потребление памяти. Зачастую это полезно в задачах компьютерного зрения, обработки языка и рекомендательных систем.

При этом стоит понимать, что в случае PINN ситуация иная. В отличие от классических задач в PINN дополнительно вычисляются производные и невязки физических уравнений, которые могут быть достаточно чувствительны к ошибкам округления.

2.6 Смешанная точность в scientific machine learning

В работе *Speeding up and reducing memory usage for scientific machine learning via mixed precision* исследуется использование смешанной точности в задачах SciML [7]. В ней показывают, что комбинация разных численных форматов может уменьшить расход памяти и ускорить вычисления. Однако для PINN низкая точность требует осторожности, поскольку при обучении вычисляются производные и невязки уравнения.

2.7 FP64 как возможное объяснение failure modes

Исходя из прошлых идей, можно прийти к идее увеличения точности представления данных. Это сделали авторы статьи *FP64 is All You Need: Rethinking Failure Modes in Physics-Informed Neural Networks* [8]. Авторы оспаривают устоявшееся объяснение проблемы обучения PINN через локальные минимумы функции потерь. Они утверждают, что при переходе от FP32 к FP64 оптимизация в ряде задач продолжает снижать ошибку там, где FP32 фактически останавливается. Эта идея используется в моей работе как основная мотивация, но проверяется на другом наборе задач.

В статьях, исследующих влияние точности на обучение PINN, обычно выделяют две главные гипотезы о том, как именно ведет себя модель в процессе оптимизации. Это Same-Basin гипотеза и Loss-Barrier гипотеза. В первом случае мы считаем, что независимо от того, учим мы модель

в FP32 или в FP64, она попадает в одну и ту же область локального минимума на ландшафте функции потерь. Разница лишь в том, что меньшему типу данных банально не хватает точности дробной части, чтобы ландшафт дна для него был ощутим. Из-за вычислительного шума при подсчете градиентов модель просто останавливается чуть выше минимума. Формат FP64 в этом случае просто позволяет аккуратно спуститься в этой же яме до самого конца. Loss-Barrier гипотеза же предполагает, что ландшафт ошибки очень сложный и содержит преграды. При обучении в FP32 модель быстро упирается в такую преграду - градиенты становятся слишком маленькими, оптимизатор перестает их "видеть" и застревает в плохом решении. Переход на FP64 дает оптимизатору достаточное разрешение, чтобы преодолеть эти барьеры и выйти из области локального минимума.

Эта работа опирается на идею статьи про роль FP64 в PINN, но проверяет её на другом наборе задач: Heat1D, Helmholtz1D, Convection1D и Burgers1D.

3 Постановка задачи

Цель работы - оценить влияние перехода от формата FP32 к FP64 на процесс оптимизации PINN в ряде одномерных задач.

3.1 Общая схема PINN

В прямой задаче необходимо найти решение $u(x, t)$ некоторого дифференциального уравнения. В PINN мы получаем аппроксимацию решения

$$u_{\theta}(x, t)$$

Дифференциальное уравнение можно записать в общем виде:

$$\mathcal{N}[u](x, t) = 0 \tag{1}$$

где $\mathcal{N}$ - дифференциальный оператор. Подставляя решение нейросети u_{θ}

получается невязка PDE:

$$PDE_\theta(x, t) = \mathcal{N}[u_\theta](x, t) \quad (2)$$

3.2 Функция потерь

PINN обучается минимизацией следующей функции потерь:

$$\mathcal{L} = \lambda_{pde}\mathcal{L}_{pde} + \lambda_{ic}\mathcal{L}_{ic} + \lambda_{bc}\mathcal{L}_{bc}. \quad (3)$$

$\mathcal{L}_{pde}$ отвечает за невязку дифференциального уравнения, $\mathcal{L}_{ic}$ задаёт ошибку на начальных точках, а $\mathcal{L}_{bc}$ задает ошибку на граничных точках.

Физическая часть функции потерь считается по набору коллокационных точек:

$$\mathcal{L}_{pde} = \frac{1}{N_{pde}} \sum_{i=1}^{N_{pde}} PDE_\theta(x_i, t_i)^2 \quad (4)$$

где N_f - число внутренних точек, в которых вычисляется невязка уравнения

Ошибки на начальных и граничных условиях считаются как средне-квадратичные ошибки между предсказанием сети и известными значениями:

$$\mathcal{L}_{ic} = \frac{1}{N_{ic}} \sum_{i=1}^{N_{ic}} (u_\theta(x_i, 0) - u_0(x_i))^2, \quad (5)$$

$$\mathcal{L}_{bc} = \frac{1}{N_{bc}} \sum_{i=1}^{N_{bc}} (u_\theta(x_i, t_i) - u_{bc}(x_i, t_i))^2 \quad (6)$$

3.3 Рассматриваемые PDE

В экспериментах используются одномерные дифференциальные уравнения, которые отличаются по сложности обучения. Формулы рассматриваемых задач приведены в таблице [1](#).

Таблица 1: Рассматриваемые уравнения

Задача	Уравнение	Параметр
Heat1D	$u_t = \alpha u_{xx}$	α
Helmholtz1D	$u_{xx} + (m\pi)^2 u = f(x)$	m
Convection1D	$u_t + \beta u_x = 0$	β
Burgers1D	$u_t + uu_x = \nu u_{xx}$	ν

Уравнение Heat1D используется в качестве базовой проверки, поскольку оно не обладает выраженными градиентными барьерами.

В задаче Helmholtz1D рассматриваются разные значения параметра m . Увеличение m увеличивает частоту решения и усложняет задачу.

Задача Convection1D рассматривается как дополнительный эксперимент, близкий к экспериментам из статьи [8].

Для задачи Burgers1D FP64 не всегда даёт устойчивое преимущество над FP32.

3.4 Сравнимые типы данных

В работе сравниваются два формата вычислений: FP32 и FP64. Для честного сравнения в выбранный тип данных переводятся параметры модели, входные точки и вычисления функции потерь.

Основной интерес представляет сравнение FP32 и FP64. В PINN обучение зависит от вычисления производных и малых значений физической невязки. Поэтому ошибки округления могут влиять не только на финальную точность, но и на сам процесс оптимизации.

3.5 Метрики качества

Для оценки качества решений используются следующие метрики: Среднеквадратичная ошибка:

$$MSE = \frac{1}{N} \sum_{i=1}^N (u_i - \hat{u}_i)^2 \quad (7)$$

Относительная L2-ошибка:

$$relative\ L2 = \frac{\|u - \hat{u}\|_2}{\|u\|_2} \quad (8)$$

u обозначает точное решение на тестовой сетке, а $\hat{u}$ - предсказание нейронной сети. Финальное сравнение проводится по лучшей L2-ошибке.

4 Реализация экспериментов

4.1 Архитектура нейронной сети

В качестве модели используется полносвязная нейронная сеть. Для нестационарных задач Heat1D, Burgers1D и Convection1D входом сети является пара координат (x, t) . Для стационарной задачи Helmholtz1D входом является только пространственная координата x .

Фактический размер модели зависит от конкретного экспериментального блока. В основных запусках использовались следующие конфигурации.

Таблица 2: Основные параметры архитектуры

Задача	Размер скрытого слоя	Число слоёв
Helmholtz1D	128	4
Convection1D, $\beta = 30$	256	3
Burgers1D	256	4

4.2 Автоматическое дифференцирование и вычисление невязок

Производные в вычислении невязки дифференциального уравнения считаются через `torch.autograd.grad`.

Heat1D уравнение

$$u_t = \alpha u_{xx}$$

Поэтому невязка имеет вид:

$$PDE_{\theta}(x, t) = \frac{\partial u_{\theta}}{\partial t} - \alpha \frac{\partial^2 u_{\theta}}{\partial x^2}$$

Точное решение для этой задачи задаётся формулой

$$u(x, t) = \exp(-\pi^2 \alpha t) \sin(\pi x)$$

Burgers1D уравнение

$$u_t + uu_x = \nu u_{xx}$$

Невязка имеет следующий вид

$$PDE_{\theta}(x, t) = \frac{\partial u_{\theta}}{\partial t} + u_{\theta} \frac{\partial u_{\theta}}{\partial x} - \nu \frac{\partial^2 u_{\theta}}{\partial x^2}$$

Начальное условие

$$u(x, 0) = -\sin(\pi x)$$

На границах $x = -1$ и $x = 1$ используется нулевое условие.

Convection1D уравнение

$$u_t + \beta u_x = 0$$

Соответствующая невязка

$$PDE_{\theta}(x, t) = \frac{\partial u_{\theta}}{\partial t} + \beta \frac{\partial u_{\theta}}{\partial x}$$

Точное решение

$$u(x, t) = \sin(x - \beta t)$$

Для этой задачи область по x задаётся на отрезке $[0, 2\pi]$, а по времени на отрезке $[0, 1]$

Для Helmholtz1D используется стационарная задача. Точное решение задано как

$$u(x) = \sin(m\pi x).$$

Правая часть строится в виде

$$f(x) = (\lambda - (m\pi)^2) \sin(m\pi x).$$

Невязка уравнения

$$u_{xx} + \lambda u = f(x)$$

Дополнительно используется нормировка невязки на величину

$$|\lambda - (m\pi)^2|$$

Нормировка нужна, чтобы задача Helmholtz при разных m измерялась в одном масштабе. Иначе при увеличении m правая часть уравнения становится больше, а вместе с ней искусственно растёт и PDE-loss. То есть фактически невязка для Helmholtz1D имеет вид

$$PDE_\theta(x) = \frac{u_{\theta,xx}(x) + \lambda u_\theta(x) - f(x)}{|\lambda - (m\pi)^2|}.$$

Физическая часть функции потерь во всех задачах считается как средний квадрат невязки:

$$\mathcal{L}_{pde} = \frac{1}{N_f} \sum_{i=1}^{N_f} PDE_\theta(x_i, t_i)^2$$

4.3 Оптимизация: Adam + L-BFGS

Обучение проводится в два этапа

$$Adam + L-BFGS$$

Сначала используется Adam, который помогает получить начальное приближение.

В основных отчётных запусках использовались разные режимы обучения для разных PDE.

Таблица 3: Основные параметры обучения экспериментах

Задача	N_f	N_{ic}	N_{bc}	Оптимизация
Helmholtz1D	5000	0	2	Adam 10000 + L-BFGS 1000/2000
Convection1D, $\beta = 30$	4225	65	65	L-BFGS 4000
Burgers1D	10000	800	800	Adam 3000 + L-BFGS 2000

В Helmholtz1D начальное условие отсутствует, так как задача стационарная. Для неё используются внутренние точки на $x \in [0, 1]$ и граничные точки $x = 0$ и $x = 1$. В основных Helmholtz-запусках также использовалось периодическое обновление коллокационных точек.

5 Результаты экспериментов

В этом разделе приведены результаты сравнения FP32 и FP64.




Рис. 1: Сравнение медианной лучшей относительной L2-ошибки для основных запусков

На рисунке 1 видно, что поведение разных задач заметно отличается. Heat1d достаточно простая задача и в обоих случаях ошибка довольно маленькая, на уровне погрешности от случайности. Для Helmholtz1D FP64 дает значительное улучшение. В случае Convection1D FP64 оказывается немного лучше. А для Burgers1D использование FP64 не дало выигрыша в качестве.




Рис. 2: Отношение медианной ошибки FP64 к медианной ошибке FP32

На рисунке 2 значение меньше единицы означает, что FP64 дал меньшую ошибку, чем FP32. Можно сравнить относительное отличие FP32 и

FP64. Становится ясно, что наибольшая разница

5.1 Heat1D

Это сравнительно простая задача, поэтому от неё не ожидается failure mode поведения.

Таблица 4: Результаты на Heat1D

Задача	Параметр	Seed FP32/FP64	FP32 best L2	FP64 best L2
Heat1D	$\alpha = 0.1$	3/3	3.753×10^{-4}	3.107×10^{-4}

В таблице 4 видно, что ожидаемо обе точности дают достаточно малую схожую ошибку. Это означает, что обе точности работают достаточно хорошо на такой простой задаче и никаких проблем с обучением не возникает.

5.2 Helmholtz1D

В задаче Helmholtz1D при увеличении ‘ m ’ увеличивается частота точного решения и его приближение становится

Таблица 5: Основные результаты на Helmholtz1D

Кейс	Seed FP32/FP64	FP32 best L2	FP64 best L2	FP64/FP32
$m = 12$	2/2	1.253×10^{-2}	2.114×10^{-3}	0.169
$m = 12$, resampling	2/2	2.160×10^{-3}	8.340×10^{-4}	0.386
$m = 12$, long run	2/2	9.213×10^{-3}	2.114×10^{-3}	0.229
$m = 7$, resampling	2/2	1.348×10^{-3}	5.144×10^{-4}	0.382
$m = 11$, resampling	2/2	1.906×10^{-3}	9.833×10^{-4}	0.516

Во всех строках таблицы 5 медианная ошибка FP64 ниже медианной ошибки FP32. Наиболее сильный эффект виден в запуске $m = 12$ медианная лучшая относительная L2-ошибка уменьшается с 1.253×10^{-2} для FP32 до 2.114×10^{-3} для FP64. Отношение FP64/FP32 равно 0.169, то есть ошибка FP64 составляет примерно 17% от ошибки FP32.

Для другого запуска с $m = 12$ и ресемплированием FP64 также лучше: ошибка уменьшается с 2.160×10^{-3} до 8.340×10^{-4} . Для $m = 7$ и $m = 11$ преимущество FP64 тоже сохраняется, хотя величина выигрыша отличается.



Рис. 3: Отношение ошибки FP64 к ошибке FP32 для Helmholtz1D

Рисунок 3 показывает, что для основных Helmholtz-запусков отношение FP64/FP32 находится ниже единицы. Это означает, что повышенная точность в этих случаях действительно помогает оптимизации прийти к более точному решению.




Рис. 4: Сравнение Helmholtz1D для разных значений параметра m

На рисунке 4 видно, что преимущество FP64 проявляется не только для одного значения m .

Отдельно рассмотрим кривые обучения для основного случая $m = 12$.




Рис. 5: Кривые обучения для Helmholtz1D, $m = 12$




Рис. 6: Фактические решения для Helmholtz1D, $m = 12$

Кривые на рисунке 5 показывают, что различие между FP32 и FP64 связано не только с финальным числом в таблице. В FP64 обучение продолжает улучшать решение до меньшей ошибки, тогда как FP32 в некоторых запусках останавливается на более высоком уровне ошибки. Это согласуется с гипотезой о том, что численная точность может влиять на прохождение failure modes в PINN.

5.3 Convection1D

Задача Convection1D используется как дополнительный baseline, близкий к failure-mode постановкам из литературы. В основной части работы рассматривается случай $\beta = 30$. Более сложный случай $\beta = 50$ не используется как главный результат, потому что он сильнее зависит от seed и требует большего числа запусков для аккуратного вывода.

Для $\beta = 30$ были получены следующие результаты.

Таблица 6: Результаты на Convection1D

Задача	Параметр	Seed	FP32/FP64	FP32 best L2	FP64 best L2
Convection1D	$\beta = 30$	2/2		1.094×10^{-2}	6.625×10^{-3}

В таблице 6 видно умеренное улучшение при переходе к FP64. Отношение FP64/FP32 для этого случая равно примерно 0.606. Это означает, что FP64 даёт меньшую ошибку, но эффект не такой сильный, как в основных Helmholtz-запусках.






Рис. 7: Кривые обучения для Convection1D, $\beta = 30$



(a) FP32



(б) FP64

Рис. 8: Фактические решения для Convection1D, $\beta = 30$

Кривые обучения на рисунке 7 показывают, что Convection1D остаётся чувствительной задачей для PINN. При этом в данном эксперименте FP64 даёт более низкую медианную ошибку, но этот результат используется как дополнительная проверка, а не как главный вывод работы.

5.4 Burgers1D: смешанный пример

Задача Burgers1D нужна для проверки того, является ли преимущество FP64 универсальным. В отличие от Helmholtz1D, здесь результаты оказались смешанными.

Таблица 7: Результаты на Burgers1D

Задача	Параметр	Seed	FP32/FP64	FP32 best L2	FP64 best L2
Burgers1D	$\nu = 0.002$	2/2		4.878×10^{-2}	4.652×10^{-2}
Burgers1D	$\nu = 0.001$	2/2		9.485×10^{-2}	1.700×10^{-1}

При $\nu = 0.002$ FP32 и FP64 дают близкие результаты: медианная лучшая относительная L2-ошибка равна 4.878×10^{-2} для FP32 и 4.652×10^{-2} для FP64. Разница есть, но она небольшая.

При $\nu = 0.001$ ситуация меняется. FP64 даёт худшую медианную ошибку, чем FP32. Для FP32 ошибка равна 9.485×10^{-2} , а для FP64 - 1.700×10^{-1} .




Рис. 9: Сравнение FP32 и FP64 на Burgers1D




Рис. 10: Фактические решения для Burgers1D, $\nu = 0.002$

Рисунок 9 подтверждает смешанный характер результатов на Burgers1D. В этой задаче на качество обучения влияют не только ошибки округления, но и сложность самой PDE, архитектура модели и работа оптимизатора.

6 Обсуждение результатов

Главный положительный результат получен на Helmholtz1D. В нескольких запусках FP64 даёт меньшую относительную L2-ошибку, чем FP32. Особенно заметен случай $m = 12$, где ошибка уменьшается с 1.253×10^{-2} до 2.114×10^{-3} в одном из основных режимов. Это хорошо

согласуется с идеей, что в некоторых PINN-задачах численная точность влияет не только на финальное значение метрики, но и на сам ход оптимизации.

Задача Heat1D успешно решается при любой точности поэтому использование ресурсоемкого FP64 здесь нецелесообразно.

Convection1D при $\beta = 30$ даёт умеренное улучшение при переходе к FP64.

Burgers1D не подтверждает гипотезу. При $\nu = 0.002$ результаты FP32 и FP64 близки, а при $\nu = 0.001$ FP64 оказался хуже. Значит, повышенная точность сама по себе не решает все проблемы обучения PINN. Скорее всего проблема failure mode здесь вовсе не возникла и функция потерь не достигла достаточно малых значений для этого. Для реальной проверки гипотезы необходимы более устойчивые запуски.

Важным фактором определяющим режим failure mode при использовании FP32 в PINN является ограничение $\epsilon \approx 1.19 * 10^{-7}$. В L-BFGS стандартно критерий остановки задается равным $\approx 10^{-7}$. Таким образом при приближении значения функции потерь к порядку $\approx 10^{-7}$, появляется нустранимая погрешность измерения и L-BFGS воспринимает полученный шум как отсутствие значимого убывания лосса и останавливает обучение. Переход к FP64 сильно сдвигает данный барьер поскольку уменьшается до $\epsilon \approx 2.22 * 10^{-16}$ Это позволяет L-BFGS продолжать корректное вычисление производных высших порядков и шагов оптимизации в сложных задачах.

7 Заключение

Работа подтверждает, что значительная часть известных режимов сбоя при обучении PINN носит не структурный характер, а чисто оптимизационный. Необходимость использования высокой точности напрямую зависит от характера ландшафта потерь конкретной физической задачи:

Для гладких диффузионных процессов (Heat1D) точности FP32 достаточно для достижения высокого качества, и избыточные вычисления

нецелесообразны.

Для жестких задач с высокой частотой колебаний (Helmholtz1D) высокая разрядность критически необходима для преодоления оптимизационных барьеров.

Для задач с сильной нелинейностью (Burgers1D) переход на FP64 сам по себе не решает проблему застревания в плохих локальных минимумах, что указывает на необходимость комбинации высокой точности со специальными методами сэмплирования или изменения архитектуры.

Список литературы

- [1] M. Raissi, P. Perdikaris, and G. E. Karniadakis, “Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations,” *Journal of Computational Physics*, vol. 378, pp. 686–707, 2019.
- [2] A. S. Krishnapriyan, A. Gholami, S. Zhe, R. M. Kirby, and M. W. Mahoney, “Characterizing possible failure modes in physics-informed neural networks,” in *Advances in Neural Information Processing Systems*, vol. 34, 2021, pp. 26 548–26 560.
- [3] A. Daw, J. Bu, S. Wang, P. Perdikaris, and A. Karpatne, “Mitigating propagation failures in physics-informed neural networks using retain-resample-release sampling,” in *Proceedings of the 40th International Conference on Machine Learning*, ser. Proceedings of Machine Learning Research, vol. 202. PMLR, 2023, pp. 7264–7302.
- [4] P. Rathore, W. Lei, Z. Frangella, L. Lu, and M. Udell, “Challenges in training PINNs: A loss landscape perspective,” in *Proceedings of the 41st International Conference on Machine Learning*, ser. Proceedings of Machine Learning Research, vol. 235. PMLR, 2024, pp. 42 159–42 191.
- [5] S. Gupta, A. Agrawal, K. Gopalakrishnan, and P. Narayanan, “Deep learning with limited numerical precision,” in *Proceedings of the 32nd International Conference on Machine Learning*, ser. Proceedings of Machine Learning Research, vol. 37. PMLR, 2015, pp. 1737–1746.
- [6] A. Gholami, S. Kim, Z. Dong, Z. Yao, M. W. Mahoney, and K. Keutzer, “A survey of quantization methods for efficient neural network inference,” *arXiv preprint arXiv:2103.13630*, 2021.
- [7] J. Hayford, J. Goldman-Wetzler, E. Wang, and L. Lu, “Speeding up and reducing memory usage for scientific machine learning via mixed precision,” *arXiv preprint arXiv:2401.16645*, 2024.

- [8] C. Xu, D. Liu, A. Nassereldine, and J. Xiong, “FP64 is all you need: Rethinking failure modes in physics-informed neural networks,” *arXiv preprint arXiv:2505.10949*, 2025.

Приложение

Пробные запуски FP16




Рис. 11: Сводка пробных запусков FP16

В рамках работы были проведены тестовые запуски обучения PINN в формате FP16. Данный формат не был включен в основную экспериментальную часть исследования, поскольку во всех тестах он показал критическую нестабильность оптимизации. В PINN функция потерь вычисляется через автоматическое дифференцирование и невязку PDE. Значения градиентов высших порядков часто оказываются меньше, чем минимально представимое число в FP16 ($6.10 \cdot 10^{-5}$), что приводит к их занулению. Так же дискретность сетки FP16 порождает сильный численный шум, из-за чего оптимизатор L-BFGS прерывает работу.